



解读耐药

一个可解释、经诚实基准检验的机器学习分类器
从细菌基因组预测抗生素耐药性

按药物逐一预测「耐药 vs 敏感」——在从未见过的谱系上验证、与透明的「基因查找」基线对比、并解释每一次判定背后的基因。

8 种 WHO 重点病原体 · 36 个模型 · 全程计算 · 仅用公共数据 · 两人团队

团队

两人协作，能力互补

软件 / 机器学习工程师

- 数据流程与特征提取
- 系统发育感知的划分
- 建模、概率校准、SHAP 工具
- 交互式演示程序

微生物学硕士

- 菌种与药物的选择
- 表型标签的质量控制
- 耐药决定因子的生物学验证
- 临床误差权衡与局限性

工程负责严谨性；微生物学掌管每一个生物学决策，并证明模型学到的是**真实机制**，而非噪声。

一口气讲完整个系统



基因组输入 → 决定因子特征

这个菌株携带哪些已知的耐药基因与突变？



逐药「耐药/敏感」+ 依据

校准后的概率，以及驱动该判定的基因。

头条结果：对于 **头孢西丁**，基因查找会漏掉 **96.3%** 的耐药株—— 因为其耐药来自孔蛋白缺失，而非获得某个基因。我们的模型把 AUC 从 0.50 提升到 0.90。这个差距就是贡献所在。

第一部分

问题及其重要性

为什么基因组能预测耐药——以及两个让粗糙项目自欺欺人的陷阱。

为何重要

耐药性写在基因组里

- 细菌耐药有两种途径：携带某个**基因**（例如能分解药物的酶）
-或药物靶点上的**点突变**。
- 标准检测是让菌株在药物下生长——准确但**缓慢**（数天）。
- 临床分离株的全基因组测序已成常规 → 已存在大量公共数据库，把基因组与**实验室表型**配对。

机遇

「从基因组预测耐药」的原材料就摆在公共数据库里。挑战不在数据——而在**诚实的评估**。

两个让粗糙结果虚高的陷阱

1 · 克隆性群体结构

细菌是**克隆繁殖**的——数据里满是同一谱系的近亲。**随机**划分训练/测试集，会让模型在训练里见过某个耐药株、又在测试里遇到它的近乎孪生体 → 于是它因**认出克隆**而非理解耐药而得分。所有指标都会虚高。

2 · 「不过是查数据库」

若模型只是检测某个已知耐药基因，那它就是**数据库查询，而非科学**。价值在于模型在此之上**额外**贡献了什么。

我们的整个设计正是针对这两点：**系统发育感知的划分** 与 一条显式的**规则基线**。

我们要证明什么

问题。一个可解释的模型，能否从基因组特征预测耐药、泛化到从未见过的谱系、并与基因查找及已发表方法进行诚实的基准对比？

假设。在系统发育感知划分下、基于决定因子特征的梯度提升模型将：

a · 在未见谱系上有强区分能力

b · 匹配/胜过基因查找，减少危险误差

c · 顶层特征 = 已知机制

九条不可协商原则，写进代码强制执行

✓ 按谱系划分，绝不随机

✓ 始终报告基因查找基线

✓ 每种抗生素一个模型

✓ VME / ME 先于准确率报告

✓ 仅用决定因子特征（不用 k-mer）

✓ 概率始终校准

✓ 不做「全面最优」的夸大

✓ 严守范围纪律

✓ 绝不伪造基因组/标签/数字

在接触数据前就已写定。一旦有单个谱系跨越划分，构建即失败（测试报错）。

第二部分

从零搭建

任何人如何从零重建本项目——环境、工具，以及可复现性的骨架。

技术栈

免费、公开、笔记本电脑可跑

Python 数据科学

Python 3.11 · pandas · numpy · scikit-learn ·
XGBoost / LightGBM · **SHAP** · matplotlib ·
scipy

生物信息学 (bioconda)

AMRFinderPlus 4.2.7 —— 耐药基因检出工具 (特征引擎)

mlst 2.33.1 —— 谱系分型

可选扩展

Streamlit —— 演示网页应用

PyTorch + **ESM-2** (fair-esm) —— 蛋白质语言模型的 MIC 扩展

笔记本电脑即可运行；ESM-2 在 Apple 芯片 GPU 上数分钟完成嵌入。

用 conda, 而非 pip 生物工具经由 bioconda 分发

从裸机到一次预测，只需 4 条命令

```
# 1 · 获取代码
git clone https://github.com/kappaborg/amr-resistance-predictor
cd amr-resistance-predictor

# 2 · 构建精确锁定版本的环境 (用 conda — 为了生物工具)
conda env create -f environment.yml
conda activate amr-resistance-predictor

# 3 · 验证可用 — 运行「零谱系泄漏」测试
make test                # -> 20 passed (20 项通过)
```

environment.yml 锁定精确的工具与数据库版本，因此任何人都能重现**相同的特征**。

科学部分绝不写死、绝不失追踪

固定随机种子 42

处处一致——划分、模型、自助抽样

config.yaml

菌种、药物、阈值、模型选择

data/manifest.md

每个来源、版本、查询、计数

Makefile

每个流程阶段一条命令

decisions.md

53 条决策记录——即实验记录本

data/raw/ 已被 git 忽略

可依据清单重新生成

第三部分

数据

公共资源、由数据驱动的菌种选择，以及维持诚实的标签纪律。

资源

五个公共来源，无需湿实验

角色	来源	提供什么
基因组 + 标签	BV-BRC	组装基因组 + 实验室 耐药/敏感表型
参考决定因子	CARD	已知耐药基因与突变的目录
特征注释	AMRFinderPlus	基因组 → 基因/突变的存在-缺失
谱系分型	mlst	每个基因组 → 序列型（谱系）
验证参照	已发表的 AMR-ML	诚实的外部对比

菌种由数据决定，而非凭直觉

- 向 BV-BRC 查询候选病原体/药物的**实验室表型计数**。
- 按**数据充足、类别均衡**的耐药/敏感来挑选。
- **锁定：肺炎克雷伯菌** (taxon 573) + 五药组合。

为何肺炎克雷伯菌契合选题

碳青霉烯类耐药正是单基因规则**失效**之处——孔蛋白缺失**加上** β -内酰胺酶的组合 → 存在真实、可捕捉的危险误差。

克隆结构强 → 系统发育感知的划分才真正**见效**。

五药组合 = **五种不同机制**：美罗培南 · 庆大霉素 · 环丙沙星 · 复方磺胺甲噁唑 (TMP-SMX) · 头孢西丁。

仅用实验室表型——避免循环论证

保留 ✓

evidence = "Laboratory Method" —— 实际测得的药敏结果。

排除 ✗

计算预测的 AMR 结果 —— 用它训练 = 在预测另一个模型的输出（循环论证）。

MIC / SIR → 二分类 耐药/敏感；含糊的「中介 (Intermediate)」类别**直接剔除，绝不臆测**（待 确认）。

严谨体现在你抓到的缺陷上

抓到：静默截断

基因组 API 默认只返回 25 条记录 → 组装被截断到约 5.5 Mbp 中的 2 Mbp。截断的基因组会**丢失基因** → 假阴性特征 → 标签被污染。由文件大小完整性检查抓到；已修复并重新下载全部。

设计上的稳健

BV-BRC REST API —— 不做批量下载，先标示大小。下载器带**退避重试并可断点续传** —— 一次超时不该毁掉整夜的运行。

与文献一致的阈值 (MIMAG)

- 完整度 $\geq 90\%$, 污染度 $\leq 5\%$ (Bowers 2017)
- contig ≤ 500 · 长度 4.5—7.5 Mbp (Kleborate 范围)
- 长度上限放宽到 7.5 Mbp —— 携带 MDR 质粒的菌株合理可达约 6.6 Mbp; 上限过紧会丢弃真实的耐药株。
- 仅剔除 1.9%, 且剔除是类别均衡的 → 不引入标签偏倚。

3,850

通过质控的肺炎克雷伯菌基因组

688

决定因子特征

第四部分

方法 —— 科学内核

特征、谱系感知划分（核心亮点）、模型、校准，以及临床指标。

基因组 → 二值决定因子矩阵

- 对每个基因组运行 AMRFinderPlus --
organism *Klebsiella_pneumoniae*。
- 构建二值矩阵：行 = 基因组，列 = 决定因子，1 = 存在。
- 只保留真正的 AMR 元件——排除毒力/应激基因。
- 纳入点突变（gyrA、parC.....）——这是氟喹诺酮类耐药的全部关键。

3,850 × 688
基因组 × 决定因子（肺炎克雷伯菌）

快速且可解释——不是黑箱 k-mer。

★ 最重要的一页

谱系感知的划分

- `mlst` 为每个基因组分配**序列型**（谱系）。
- `StratifiedGroupKFold` 将**整个谱系**留作测试——模型只在**从未见过的**序列型上受测。
- 划分中保持耐药/敏感类别均衡。
- 无法分型的基因组各自获得一个**唯一**的合成谱系——绝不会悄悄并入一个会泄漏的组。

守卫

一项测试断言训练与测试间**零谱系重叠**——对全部 8 种菌。一旦某序列型同时出现在两侧，**构建即失败**。

`tests/test_split.py` · 20 项测试通过

正是这一选择，让此后每个数字都可信。

我们量化了所避免的泄漏

同一模型，在朴素随机划分与我们的谱系划分下分别评分：

+0.010

随机划分带来的 AUC 平均虚高（最大 +0.032，头孢西丁）

虚高很小——因为我们的特征编码的是机制，而非血统。一个基因组耐药，是因为它携带 blaKPC，而不是因为它的进化枝。

对照

k-mer 模型——暗中编码谱系——在同一测试上会损失 **0.1–0.2 AUC**。

我们这么小的差距本身就是**学到生物学**的证据。我们仍处处报告诚实的谱系数字。

建模

每种抗生素一个模型，三个诚实层级

1 · 规则基线

「只要存在该药已知的任一基因即判耐药。」透明的标尺。

2 · 逻辑回归

简单、线性、可解释的参照。

3 · XGBoost

梯度提升——主模型。经校准并设定阈值。

耐药是药物特异的 → **绝不把多种药并成一个标签**。三者都报告，好让「机器学习额外贡献了什么」保持诚实。

公平性 🔗

基因查找基线随菌种而变

「氨苄西林耐药」在不同细菌里并非同一个基因：

大肠埃希菌 → β -内酰胺酶

肠球菌 → pbp5

肺炎链球菌青霉素 → pbp1a/2b/2x 镶嵌型

单一通用规则在某些菌里会成为**稻草人**基线。ORG_RULES 按(菌种, 药物)匹配**真实机制**——因此我们胜过基线时，胜过的是**真实的基线**。

有意义的概率 · 真正要紧的误差

校准

保序校准 + Brier 分数 + 可靠性曲线。「90% 耐药」应约有 90% 的时候是对的——一个实为 0.6 的未校准 0.9 是危险的。

VME / ME —— 优先报告

极重大误差 (VME)：把耐药误判为敏感——病人用了无效的药。**危险的漏判。**

重大误差 (ME)：把敏感误判为耐药——不必要的警报。

工作点调到把 **VME 控制在 $\leq 3\%$** (CLSI/FDA 风格)。

在难判的药上，压低 VME 会抬高 ME——这是一种临床权衡，**公开呈现**，绝不隐藏。


第五部分

训练与流程

这条流水线——每一个环节都是一个可运行的文件。

端到端

基因组 → 可解释、经基准检验的预测



每个阶段一条命令 — 或一次跑完整条主线

```
make data · features · split · train · eval · figures # make all
```

两个决策关口：「每种药是否有足够的 R 和 S？」以及「能否泛化到未见谱系？」——若不能，则回到划分重来。

模型如何构建

绝不偷看测试集

- 在训练谱系上拟合 XGBoost。
- 校准（保序）。
- 在折外训练预测上选取 $VME \leq 3\%$ 阈值——绝不用测试集。
- 在留出谱系上只评估一次。

可部署的打包

模型 + 校准器 + 阈值 + 特征列 → 每个「菌种-药物」一个 .joblib

36

可部署模型（8 种菌）

第六部分

结果

在未见谱系上有强区分能力——并对「查找已经占优之处」
保持诚实。

头条结果

头孢西丁——查找失效之处

0.52

基因查找 AUC (掷硬币)



0.90

模型 AUC (DeLong $p \approx 0$)

其耐药由 **ompK36 孔蛋白缺失** 驱动——药物进不来。基因查找对**缺失**的特征是盲的 (漏掉 96.3% 的耐药株)。模型学会了这种「缺失」的模式。

这是「机器学习相对数据库查询能带来什么」最干净的证明。

全面且具统计显著性

药物	模型 AUC	规则 AUC	VME	ME	DeLong p
环丙沙星	0.983	0.911	2.3%	7.7%	7e−36
复方磺胺甲噁唑	0.977	0.885	2.3%	18.3%	9e−51
美罗培南	0.968	0.933	1.3%	55.9%	5e−24
庆大霉素	0.981	0.948	1.6%	32.4%	1e−30
头孢西丁	0.905	0.518	0.7%	94.2%	~0

五种药的 VME 点估计均满足 $\leq 3\%$ 标准 · 在全部五种药上都**显著**胜过查找。诚实说明：按谱系聚类的自助置信区间较宽（美罗培南 1.3% [0.3–3.5]），因此该目标是在**期望意义上**达成，而非在置信上界得到保证。美罗培南/头孢西丁的高 ME 是 VME 优先的权衡，已用标记呈现。

诚实的解读 📖

我们^不占优之处——主动先说

庆大霉素

规则已经很强 (AUC 0.948)
——直接的酶信号。机器学习
只是**持平**。我们照实说。

沙门菌氯霉素

规则基线**胜过**我们的模型。如
实报告。


肺炎链球菌 TMP-SMX

作为耐药根源的 folA/folP **不在目录内** → 任何信号都是**共选择**，而非机制。据实标注。

拿奖靠的不是宣称样样都赢——而是**清楚知道自己在哪里不赢**。


泛化能力

8 种 WHO 重点病原体 · 同一流程



未见谱系 ROC-AUC，8 种菌 × 至多 18 种药（36 个校准模型）。ROC 0.84—0.998。

模型学到的是生物学，而非谱系



在一种菌上训练，零样本测试于另一种。非对角线 = 迁移。

环丙沙星在**革兰氏阴性菌之间**迁移良好（共享 gyrA/parC 靶点与位点编号）

.....而在革兰氏阳性的金黄色葡萄球菌上**崩塌**（其用 grlA，且 gyrA 编号不同）。

一个在机制上**可预期**的边界——若模型只是记住谱系伪影，绝不可能出现。

统计严谨性

结论有统计支撑

DeLong 检验

模型在区分能力上**显著**胜过基因查找——每种药， p 从 $2e-14$ 到 ~ 0 。

谱系聚类自助法

重采样**整个谱系**而非单个基因组的 95% 置信区间——对小的耐药类别更诚实。

抗不平衡指标

MCC + 现实患病率下的 PPV/NPV——单看准确率会美化我们。

我们的 AUC 位于已发表区间之内/之上——但是在**更严格**的谱系划分下，还附带多数研究省略的可解释性与临床误差。结论是：**诚实测得**，而非全面最优。

第七部分

进阶与创新扩展

MIC 回归 · 蛋白质语言模型 · 一个诚实的负面结果 · 不确定性与临床效用。

超越二分类

MIC 回归——预测耐药程度

临床以 MIC（最低抑菌浓度）思考。我们连续地预测它，并按监管方式评分：**基本一致性（EA）**——在 ± 1 个二倍稀释度以内。

删失感知的评分——多数真实 MIC 是「 >32 」 / 「 ≤ 0.5 」这样的界值；朴素截断会扭曲指标。

药物（肺炎克雷伯菌）	基本一致性（EA）
环丙沙星	92.7%
庆大霉素	85.1%
头孢西丁	79.9%
美罗培南	75.4%

ESM-2——为难缠的碳青霉烯类做等位基因级分辨

存在/缺失丢弃了**是哪个等位基因**——但碳青霉烯类的 MIC 依赖于此 (KPC-2 对 KPC-3; OXA/NDM/VIM)。我们用 ESM-2 嵌入每个耐药蛋白的**实际序列**，使不同等位基因得到不同向量。

真实、显著的增益——恰在预期之处

肺炎克雷伯菌美罗培南 EA **68 → 73%**
(+4.8, $p=0.0004$)

鲍曼不动杆菌亚胺培南 EA **54 → 60%**
(+6.7, $p=0.0001$)

在决定因子已饱和之处保持中性 (庆大霉素、环丙沙星)。650M 相较 150M 无额外增益 → 150M 是诚实、笔记本电脑可跑的选择。

诚实的负面结果——答辩亮点

我们实现了前沿图模型。它输了。

菌株相似性图神经网络

每个基因组为一个节点，按相似性连边（AMR-GNN 风格）。在相同的谱系分组折上，它在**全部 5 种药上都不如一个普通 MLP**。

原因——而且我们能解释

我们精选的决定因子特征已经干净地捕捉了机制信号。群体结构图只会重新引入**我们刻意规避的谱系信息**，其平滑还会模糊清晰的「基因→表型」边界。

「我们测试了前沿方法，它没赢，原因如下」——比假设它会有用**更有力**的立场。

一个「知道自己何时不知道」的模型

保形预测的弃判

逐类覆盖率 + 一个显式的

「转交表型药敏检测」选项。数据充足的药可自信处理约 95%；难缠的碳青霉烯类在**近乎零 VME** 下自信判定约 55%，其余转交。已在谱系偏移下验证。

决策曲线与风险-覆盖率

在 VME 敏感区间内，净获益胜过查找与「全部治疗」。转交最不自信的**约 30%** 可将 VME 大致**减半**（美罗培南 8.7% → 3.5%）。


第八部分 4

可解释性与生物实验验证

微生物学家的部分——模型依赖的是真实机制吗？

SHAP

每次判定都指名其基因



美罗培南 SHAP —— blaKPC-2 / blaKPC-3 位列首要决定因子（碳青霉烯酶）。逐株、可审计。

顶层特征 = 教科书机制

药物	模型的顶层决定因子	已知机制	✓
环丙沙星	gyrA、parC (QRDR) + qnr	DNA 促旋酶 / 拓扑异构酶靶点突变	✓
庆大霉素	aac(3) 乙酰转移酶	氨基糖苷修饰酶	✓
复方磺胺甲噁唑	sul1、dfrA	二氢蝶酸合成酶 / 二氢叶酸还原酶旁路	✓
美罗培南	blaKPC-2、blaKPC-3	碳青霉烯酶	✓
头孢西丁	ompK36 孔蛋白缺失	药物进入减少 (缺失, 而非获得)	✓
金黄色葡萄球菌苯唑西林	mecA	变异的 PBP2a	✓
屎肠球菌氨苄西林	pbp5	变异的青霉素结合蛋白	✓
肺炎链球菌青霉素	pbp1a/2b/2x 镶嵌型	变异的青霉素结合蛋白 (镶嵌型)	✓

诚实的告诫：共选择会抬高某些同载质粒标记的表观重要性 → 应看逐株 SHAP，而非仅看均值。仅限已编目的决定因子 → 无新基因发现（需泛基因组特征）。

第九部分

演示

一个可用的网页应用——输入基因组，输出可解释的逐药判定。

交互式应用

8 种菌 · 上传基因组 · 获得可解释判定

- 选择菌种 → 缓存基因组或上传 FASTA。
- 实时运行 AMRFinderPlus → 逐药 耐药/敏感 + 校准的 P(耐药) + SHAP 驱动因子。
- 可选的 AI 临床解读——仅为解释层，**绝不**改变判定；无 API 密钥时使用确定性模板。

```
# 实时  
python -m streamlit run src/app/streamlit_app.py
```

已验证示例

金黄色葡萄球菌基因组 →

苯唑西林 耐药 (P=0.94)

驱动因子: **mecA** ↑、erm(C) ↑

环丙沙星 耐药 (P=0.98)

驱动因子: **gyrA_S84L**、**parC_S80F** ↑

安全

物种守卫

模型是决定因子向量的函数——它会对**任何**输入「预测」（曾有一个真菌文件产生过虚假判定）。

因此应用以**两种独立方式**核验物种：

- **MLST 方案**（物种特异的分型）
- **固有标记基因**（对蛋白质输入也有效）

不匹配 → **不予给出预测。**

每个界面

「仅供研究/决策支持——**非诊断用途。**
补充、而非取代表型药敏试验。」

第十部分

优点与缺点——诚实呈现

两者都应上幻灯片。局限正是诚实这一主张的兑现之处。

优点

为何达到获奖级别

- **诚实源自构造**——谱系划分由会让构建失败的测试强制执行。
- **在要紧之处胜过查找**，并有 DeLong 显著性。
- **泛化到 8 种病原体及革兰氏分界**；沿机制线零样本迁移。
- **可解释**——每次判定都被指名并经生物学验证。
- **以临床为框架**——VME 优先、经校准、可弃判、算净获益。
- **超越二分类**——MIC + ESM-2 等位基因级分辨。
- **严谨的负面结果**——GNN 经测试并被否定，且有理由。
- **可复现**——锁定环境、随机种子、清单、53 条决策、20 项测试。

评委会问的问题——我们先自问

- 范围——8 种菌，每种约 3—5 种药；并非通用工具。
- 共选择会抬高某些同载决定因子（已减轻，未消除）。
- $VME \leq 3\%$ 下难判药的高 ME——是阈值权衡，而非区分能力失败。
- 数据库偏倚——CARD/BV-BRC 偏向测序充分的地区。
- 仅用决定因子特征——无新基因发现。
- 若干诚实的弱点——沙门菌氯霉素、鲍曼不动杆菌碳青霉烯类、肺炎链球菌 TMP-SMX。
- 鲍曼不动杆菌美罗培南 MIC 增益处于临界 ($p=0.051$ ，样本不足)。
- 与已发表的对比是区间级，而非逐一重跑对照。

自己主动提出的局限读作**功力**；被追问出来的则读作漏洞。

为受检验而建，而非为被信任

伦理

- 决策支持，非诊断器械
- 补充表型试验——故 VME 优先
- 仅用公共、去标识化数据；坦述数据库偏倚
- 可解释性 = 一种伦理保障

可复现性

- 锁定环境 + 固定随机种子
- 数据清单 + 53 条决策记录
- 任何人可运行的 20 项测试
- 原始数据可依清单重新生成



诚实测得

不是「全面最优」——而是可信

0.50→0.90

头孢西丁：查找 → 模型

8 · 36

病原体 · 可部署模型

我们做的最重要的一件事：由测试强制执行的谱系感知划分。下游的一切之所以可信，全靠它。